



PRAHA CODINGSCHOOL


Python Pandas

Výběr dat, filtrování
Operace s tabulkami a daty
Lektor: Martin Rosický




PANDAS

svatý grál analýzy dat





Pandas: základem je DataFrame



source: <https://pandas.pydata.org/>

- Univerzální nástroj pro zpracování a analýzu dat
- Základ tvoří
 - pandas.Series (1D data)
 - pandas.DataFrame (2D data)
- Široká paleta nástrojů pro import/export dat
- Manipulace s daty inspirovány (, ale ne omezené na) SQL
- Vyvinuto s důrazem na výkon



PANDAS

svatý grál analýzy dat

Zobrazení dat

Řazení

Filtrování





Eclipse PyDev Console

```
> import pandas  
> sklad = pandas.read_csv(<vytvořený csv soubor>)  
>  
> sklad.info()  
<class 'pandas.core.frame.DataFrame'>  
RangeIndex: 807 entries, 0 to 806  
Data columns (total 9 columns):  
 #   Column      Non-Null Count  Dtype     
 ---  --          -----          ----  
 0   skupina     807 non-null    object    
 1   pid         807 non-null    object    
 2   produkt     807 non-null    object    
 3   varianta    807 non-null    object    
 4   prodej      807 non-null    float64  
 5   nakup       807 non-null    float64  
 6   skladem     807 non-null    int64     
 7   prodano     807 non-null    int64     
 8   marze       807 non-null    float64  
dtypes: float64(3), int64(2), object(4)  
memory usage: 56.9+ KB
```

```
# import knihovny pandas  
# import dat z csv  
  
# zobrazení informace o datech
```



Náhled dat

```
> sklad
      # zobrazení vzorku dat
  skupina      pid   produkt ... skladem prodano marze
0  kosmetika    19106     olej ...    71     48  28.72
1  kosmetika    1910     olej ...    75     51  14.37
2  kosmetika    19376     olej ...    87     99  13.51
3  kosmetika    1937     olej ...    51     17  13.23
4  kosmetika    19503     olej ...    81     77  13.86
...
802  mobily  100153992486594583     sony ...    49     84  11.91
803  mobily  100153992486594584  microsoft ...    91    101  25.44
804  mobily  100153992486594585    yealink ...    32     28  13.73
805  mobily  100153992486594586    yealink ...    13     96  11.28
806  mobily  100153992486594587    yealink ...     1     39  11.57

[807 rows x 10 columns]
```



Výběr sloupců a řazení

```
> sklad[['varianta','prodej','nakup']] # výběr sloupců podle jména
          varianta    prodej    nakup
0      ČISTÍCÍ OLEJ NA PLEŤ 3 v 1 - 50 ml  277.69   197.95
1      ČISTÍCÍ OLEJ NA PLEŤ 3 v 1 - vzorek 13 ml  65.29    55.91
..           ...
806          Yealink SIP-T33G  1303.31  1152.56
> sklad.iloc[9:15,3:6] # výběr rozsahem řádků a sloupců
          varianta    prodej    nakup
9      JOJOBOVÝ OLEJ LZS - 100 ml  276.03   231.88
10     ROSA FEMINNE CREME (růžový krém) - 30 ml  401.65   329.17
11      KRÉM NA DOBRÉ RÁNO - 30 ml  317.36   279.99
12      LALIUM - MAST - 5 ml    91.74    78.15
13      LALIUM - MAST - 50 ml  262.81   192.05
14      LALIUM - MAST - 100 ml  462.81   398.35
```



Řazení; vícesložkové, sestupně

```
> sklad[['varianta','prodej','nakup']].sort_values('prodej')
      varianta    prodej    nakup
619          RAVENSARA AROMATICA - 100 ml    1.00    0.82
433    LÉKOVKA SKLENĚNÁ HNĚDÁ 50ml - balení 105 ks    1.00    0.89
552  DELFÍNEK - DĚTSKÝ KOUPELOVÝ OLEJ velký - 1000 ml    1.00    0.71
415    LÉKOVKA SKLENĚNÁ HNĚDÁ 10ml - balení 160 ks    1.00    0.74
...
> sklad[['varianta','prodej','nakup']].sort_values(['prodej','nakup'])
      varianta    prodej    nakup
147          MANUKA - 20 ml    1.00    0.71
552  DELFÍNEK - DĚTSKÝ KOUPELOVÝ OLEJ velký - 1000 ml    1.00    0.71
192          SMRK ZTEPILÝ, jehličí, PSP - 100 ml    1.00    0.73
435    LÉKOVKA SKLENĚNÁ HNĚDÁ 20ml - balení 180 ks    1.00    0.73
...
> sklad[['varianta','prodej','nakup']].sort_values(['prodej','nakup'],ascending=False)
      varianta    prodej    nakup
693      Apple iPhone 14 Pro Max 1 TB Space Black  44195.87  33818.95
694      Apple iPhone 14 Pro 1 TB Space Black   41303.31  30418.62
695      Apple iPad Pro 12.9 2022 512 GB Space Grey  40476.86  34688.01
741      Samsung Galaxy Z Fold4 512 GB   39650.41  32816.99
...
...
```



Filtrování dat

```
> sk = sklad[['varianta','prodej','nakup']]      # ,sk` je obdobou view  
> sk[(sk['prodej'] >= 10) & (sk['prodej'] <= 20)]
```

	varianta	prodej	nakup
312	LÁHEV PET S UZÁVĚREM BÍLÁ 30ml	14.88	10.80
313	LÁHEV PET S UZÁVĚREM BÍLÁ 50ml	15.70	14.03
316	LÉKOVKA SKLENĚNÁ HNĚDÁ 100ml - 1 ks	18.18	12.94
319	DÓZA PLASTOVÁ BÍLÁ - 5 ml	14.88	10.56
320	DÓZA PLASTOVÁ BÍLÁ - 30 ml	18.18	14.60
321	DÓZA PLASTOVÁ BÍLÁ - 50 ml	19.83	17.75
432	LÉKOVKA SKLENĚNÁ HNĚDÁ 50ml - 1 ks	14.88	12.94
..
547	KAPACÍ SKLENĚNÁ PIPETA na lékovku 10ml	16.53	11.94
548	KAPACÍ SKLENĚNÁ PIPETA na lékovku 20ml	17.36	14.20
549	KAPACÍ SKLENĚNÁ PIPETA na lékovku 50ml	18.18	13.36
550	KAPACÍ SKLENĚNÁ PIPETA na lékovku 100ml	19.01	13.55
556	KAPACÍ SKLENĚNÁ PIPETA na lékovku 30ml	17.36	15.05
672	DÁVKOVACÍ PUMPIČKA k výrobkům o objemu 500 ml	15.70	12.72
683	LÁHEV 0.5 l - plast	12.40	9.31
684	LÁHEV 1 l - plast	17.36	13.19



Filtrování textu

```
> sk[sk['varianta'].str.contains(" PET ")]      # vyhledání řetězce
            varianta prodej nakup
307        Láhev PET se sprejem, bílá, 100ml 23.97 20.63
311        Láhev PET se sprejem čirá 30ml 21.49 17.33
312        LÁHEV PET S UZÁVĚREM BÍLÁ 30ml 14.88 10.80
...
315        LÁHEV PET S ODKLÁPĚCÍM UZ. ČIRÁ 200ml 23.14 17.58
447    LÁHEV PET S ODKLÁPĚCÍM UZ. ČIRÁ PLOCHÁ 100ml 13.22 11.00
580        LÁHEV PET S ODKLÁPĚCÍM UZ. bílá 200ml 23.14 17.89
> sk[sk['varianta'].str.contains(r"\bPET\b")]      # vyhledání regulárním výrazem
            varianta prodej nakup
307        Láhev PET se sprejem, bílá, 100ml 23.97 20.63
311        Láhev PET se sprejem čirá 30ml 21.49 17.33
312        LÁHEV PET S UZÁVĚREM BÍLÁ 30ml 14.88 10.80
...
315        LÁHEV PET S ODKLÁPĚCÍM UZ. ČIRÁ 200ml 23.14 17.58
447    LÁHEV PET S ODKLÁPĚCÍM UZ. ČIRÁ PLOCHÁ 100ml 13.22 11.00
580        LÁHEV PET S ODKLÁPĚCÍM UZ. bílá 200ml 23.14 17.89
```



Ignorování velikosti písmen

```
> sk[sk['varianta'].str.contains(r"\bpet\b")]      # funkce rozlišuje velikost písmen
Empty DataFrame
Columns: [varianta, prodej, nakup]
Index: []

> sk[sk['varianta'].str.contains(r"\bpet\b", case=False)] # bez rozlišení velikosti
   variantá    prodej    nakup
307 Láhev PET se sprejem, bílá, 100ml  23.97  20.63
311 Láhev PET se sprejem čirá 30ml    21.49  17.33
312 LÁHEV PET S UZÁVĚREM BÍLÁ 30ml  14.88  10.80
313 LÁHEV PET S UZÁVĚREM BÍLÁ 50ml  15.70  14.03
314 LÁHEV PET S UZÁVĚREM BÍLÁ 100ml 20.66  14.74
315 LÁHEV PET S ODKLÁPĚCÍM UZ. ČIRÁ 200ml 23.14  17.58
447 LÁHEV PET S ODKLÁPĚCÍM UZ. ČIRÁ PLOCHÁ 100ml 13.22  11.00
580 LÁHEV PET S ODKLÁPĚCÍM UZ. bílá 200ml 23.14  17.89
```



Kombinace filtru a výběru sloupců

```
> sk.loc[sk['varianta'].str.contains(r"\bpet\b", case=False), ['varianta', 'prodej']]
```

	varianta	prodej
307	Láhev PET se sprejem, bílá, 100ml	23.97
311	Láhev PET se sprejem čirá 30ml	21.49
312	LÁHEV PET S UZÁVĚREM BÍLÁ 30ml	14.88
313	LÁHEV PET S UZÁVĚREM BÍLÁ 50ml	15.70
314	LÁHEV PET S UZÁVĚREM BÍLÁ 100ml	20.66
315	LÁHEV PET S ODKLÁPĚCÍM UZ. ČIRÁ 200ml	23.14
447	LÁHEV PET S ODKLÁPĚCÍM UZ. ČIRÁ PLOCHÁ 100ml	13.22
580	LÁHEV PET S ODKLÁPĚCÍM UZ. bílá 200ml	23.14



PANDAS

svatý grál analýzy dat

Agregace dat





Agregace dat

```
> on_stock = sklad.groupby('produkt')['skladem'].sum()
> on_stock.sort_values()
produkt
extrakt      3
katalog      4
kabelka      9
cat         14
garmin      15
...
balzám     893
samsung    1099
apple       1755
olej        6892
esence     19684
Name: skladem, Length: 70, dtype: int64
```



PANDAS

svatý grál analýzy dat

Přidávání sloupců
Spojování tabulek





Spojení tabulek „UNION“

```
> top_sellers = sklad.groupby('produkt')['prodano'].sum().sort_values(ascending=False).head(5)
> low_sellers = sklad.groupby('produkt')['prodano'].sum().sort_values(ascending=False).tail(5)

> toplow_sellers = pandas.concat([top_sellers,low_sellers],axis=0)
> toplow_sellers
produkt
esence      23364
olej         8048
apple        1863
samsung      1287
lékovka      931
nová          30
katalog       30
comtrend     21
testovací     15
kabelka      11
Name: prodano, dtype: int64
```



Spojení tabulek podle společné hodnoty

```
> sold = sklad.groupby('produkt')['prodano'].sum()  
> stocksold = pandas.merge(on_stock,sold,how="left",on="produkt")  
> stocksold
```

produkt	skladem	prodano
alcatel	193	138
alfalfa	152	327
apple	1755	1863
aroma	387	419
aroma-andílek	89	63
...
čichová	101	42
ředkev	462	536
ředící	130	267
řepa	630	792
řeřicha,	275	312



Přidání nového sloupce

```
> sklad['hodnota'] = sklad['skladem'] * sklad['nakup']
> sklad['vynos'] = sklad['prodano'] * sklad['prodej']
> sklad['zisk'] = sklad['prodej'] - sklad['nakup']
> sklad.info()
<class 'pandas.core.frame.DataFrame'>
RangeIndex: 807 entries, 0 to 806
Data columns (total 12 columns):
 #   Column      Non-Null Count  Dtype  
---  --  
 0   skupina     807 non-null    object 
 1   pid         807 non-null    object 
 2   produkt     807 non-null    object 
 3   varianta    807 non-null    object 
 4   prodej      807 non-null    float64
 5   nakup       807 non-null    float64
 6   skladem     807 non-null    int64  
 7   prodano     807 non-null    int64  
 8   marze       807 non-null    float64
 9   hodnota     807 non-null    float64
 10  vynos       807 non-null    float64
 11  zisk        807 non-null    float64
dtypes: float64(6), int64(2), object(4)
memory usage: 82.1+ KB
```



Přidání sloupců voláním funkce

```
def build_new_columns(key, row):          # definice funkce
    ...
    output = [key, id, produkt, mnozstvi]  # výstupem je list hodnot,
    return output                          # které se uloží do DF

df[['skupina', 'id', 'produkt', 'množství']] = df.apply(
    lambda row: build_new_columns('kosmetika', row),
    axis=1,                                # pracujeme s řádky
    result_type='expand'                   # rozdělí list do sloupců
)
```